

8장 6~9 텍스트 분석

6. 토픽 모델링

문서 집합에 숨어 있는 주제를 찾아내는 것을 말함. → 숨겨진 주제를 효과적으로 표현할 수 있는 중심 단어를 함축적으로 추출

LSA:latent semantic analysis

LDA:latent dirichlet allocation(사이킷 런 제공)

7. 문서 군집화

비슷한 텍스트 구성의 문서를 군집화 하는 것을 말함.

동일한 군집에 속하는 문서를 같은 카테고리 소속으로 분류할 수 있으므로 앞에서 소개한 텍스트 분류 기반의 문서 분류와 유사

그러나,


텍스트 분류 기반의 문서 분류는 사전에 결정 카테고리 값을 가진 학습 데이터 세트가 필요한 데 반해, 문서 군집화는 학습 데이터 세트가 필요 없는 비지도학습 기반으로 동작

opinion review 데이터 셋을 이용한 문서 군집화 수행하기

LemNormalize() 함수를 만들겠습니다(해당 함수는 이전에 설명드린 단어 토큰화, 스톱 워드 제거, 어근 변환에 기반하고 있기에 여기서 언급 드리지 않고, 부록으로 제공되는 소스 코드에서 보다 자세한 설명을 드리고 있으니, 참조 부탁드립니다

8. 문서 유사도

일반적으로 코사인 유사도 사용. 벡터의 상호 방향성이 얼마나 유사한지에 기반함. 두 벡터 사이의 사잇각을 구해서 얼마나 유사한지 수치로 적용한 것을 말함.



두 벡터 A와 B의 코사인 값은 다음 식으로 구할 수 있습니다(고등학교 때 배웠겠지만, 아마 기억의 흔적이 없을 것입니다). 두 벡터 A와 B의 내적 값은 두 벡터의 크기를 곱한 값의 코사인 각도 값을 곱한 것입니다.

$$A \cdot B = \|A\| \|B\| \cos \theta$$

따라서 유사도 $\cos \theta$ 는 다음과 같이 두 벡터의 내적을 총 벡터 크기의 합으로 나눈 것입니다(즉, 내적 결과를 총 벡터 크기로 정규화(L2 Norm)한 것입니다).

$$\text{similarity} = \cos \theta = \frac{A \cdot B}{\|A\| \|B\|} = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \sqrt{\sum_{i=1}^n B_i^2}}$$

왜?

문서를 피처 벡터화 변화하면 차원이 매우 많은 희소행렬이 되기 쉬운데, 이 경우 유클리드 거리 기반 지표는 정확도가 떨어짐.

사이킷런은 코사인 유사도를 측정하기 위해 `sklearn.metrics.pairwise.cosine_similarity` API를 제공

→ ndarray 형태로 제공할 수도 있음.

9. 한글 텍스트 처리

한글언어처리는 영어 등의 라틴어 처리보다 어렵습니다. 그 주된 원인은 '띄어쓰기'와 '다양한 조사' 때문

워낙 경우의 수가 많기 때문에 어근 추출(Stemming/Lemmatization) 등의 전처리 시 제거 하기가 까다로움.

KoNLPy : 대표적인 한글 형태소 패키지

형태소 분석(Morphological analysis)이란 말뭉치를 이러한 형태소 어근 단위로 쪼개고
각 형태소에 품사 태깅(POS tagging)을 부착하는 작업을 일반적으로 지칭