

9장 정리

추천 시스템 개요

온라인 스토어는 많은 양의 고객과 상품 관련 데이터를 가지고 있습니다. 이 모든 데이터가 사용자가 흥미를 가질 만한 상품을 즉각적으로 추천하는 데 사용

예시 데이터: 사용자가 어떤 상품을 구매했는가? 사용자가 어떤 상품을 둘러보거나 장바구니에 넣었는가? 사용자가 평가한 영화 평점은? 사용자가 스스로 작성한 자신의 취향은? 사용자가 무엇을 클릭했는가?

크게 콘텐츠 기반 필터링과 협업 필터링으로 나뉨

-협업 필터링 방식은 다시 최근접 이웃(Nearest Neighbor) 협업필터링과

-잠재 요인(Latent Factor) 협업 필터링 (넷플릭스는 행렬 분해(Matrix Factorization) 기법을 이용)

콘텐츠 기반 필터링

사용자가 특정한 아이템을 매우 선호하는 경우, 그 아이템과 비슷한 콘텐츠를 가진 다른 아이템을 추천하는 방식

예시: 영화 추천,

사용자가 선호하는 감독, 장르, 키워드 등의 콘텐츠를 다양하게 포함하고 있으므로 콘텐츠 기반 필터링 추천 시스템에 의해서 해당 영화가 추천되도록 할 수 있음.

협업 필터링(최근접 이웃, 잠재 요인)

사용자가 아이템에 매긴 평점 정보나 상품 구매 이력과 같은 사용자 행동 양식(User Behavior)만을 기반으로 추천을 수행하는 것

주요 목표: 사용자—아이템 평점 매트릭스와 같은 축적된 사용자 행동 데이터를 기반으로 사용자가 아직 평가하지 않은 아이템을 예측 평가하는 것임.

최근접 이웃 방식과 잠재 요인 방식으로 나뉨 → 두 방식 모두 행렬 데이터에만 의지해 추천을 수행함.

행: 개별 사용자 열: 개별 아이템. 으로 나뉘어져야 함.

로우 레벨 형태의 사용자 -아이템 평점 데이터

User ID	Item ID	Rating
User 1	Item 1	3
User 1	Item 3	3
User 2	Item 1	4
User 2	Item 2	1
User 3	Item 4	5

변환

사용자 로우, 아이템 칼럼으로 구성된 사용자 -아이템 평점 데이터

	Item 1	Item 2	Item 3	Item 4
User 1	3		3	
User 2	4	1		
User 3				5

많은 아이템을 열로 가지는 다차원 행렬이자, 사용자가 아이템에 평점을 매기는 경우가 적어 희소행렬의 형태를 띄게 됨.

• 최근접 이웃 협업 필터링

-사용자 기반(User—User) : 당신과 비슷한 고객들이 다음 상품도 구매했습니다 (Customers like you also bought these items).

특정 사용자와 유사한 다른 사용자를 Top-N으로 선정해 이 사용자가 좋아하는 제품을 추천. 즉, 특정 사용자와 다른 사용자 간의 유사도를 추출하는 것이 중요함.

		다크 나이트	인터스텔라	엣지오브 투모로우	프로메테우스	스타워즈 라스트제다이
상호간 유사도 높음	사용자 A	5	4	4		
	사용자 B	5	3	4	5	3
	사용자 C	4	3	3	2	5

사용자 A는 사용자 C보다 사용자 B와 영화 평점 측면에서 유사도가 높음. 따라서 사용자 A에게는 사용자 B가 재미있게 본 '프로메테우스'를 추천

-아이템 기반(Item-item) : 이 상품을 선택한 다른 고객들은 다음 상품도 구매했습니다(customers who bought this item also bought these items).

사용자들이 그 아이템을 좋아하는지/싫어하는지의 평가 척도가 유사한 아이템을 추천하는 기준이 되는 알고리즘

		사용자 A	사용자 B	사용자 C	사용자 D	사용자 E
상호간 유사도 높음	다크 나이트	5	4	5	5	5
	프로메테우스	5	4	4		5
	스타워즈 라스트제다이	4	3	3		4

여러 사용자들의 평점을 기준으로 볼 때 '다크 나이트'와 가장 유사한 영화는 '프로메테우스'

일반적으로 사용자 기반보다는 아이템 기반 협업 필터링이 정확도가 더 높음. 왜냐하면 비슷한 것을 소비한다고 진짜 취향이 비슷한 것은 아닌 경우가 있기 때문.

코사인 유사도는 추천 시스템의 유사도 측정에 가장 많이 적용

잠재 요인 협업 필터링

잠재 요인 협업 필터링은 사용자-아이템 평점 매트릭스 속에 숨어 있는 잠재 요인을 추출해 추천 예측을 할 수 있게 하는 기법

행렬 분해: 대규모 다차원 행렬을 SVD와 같은 차원 감소 기법으로 분해하는 과정에서 잠재 요인을 추출

1. 다차원 희소 행렬인 **사용자-아이템 행렬 데이터**를 저차원 밀집 행렬의 **사용자-잠재 요인 행렬 + 아이템-잠재 요인 행렬의 전치 행렬** (즉, 잠재 요인-아이템 행렬)로 분해
2. 이렇게 분해된 두 행렬의 내적을 통해 새로운 **예측 사용자-아이템 평점 행렬 데이터**를 만들어서 사용자가 아직 평점을 부여하지 않는 아이템에 대한 예측 평점을 생성하는 것

사용자-아이템 평점 행렬(R)을 두 개의 저차원 행렬인 ****사용자-잠재 요인 행렬(P)****과 ****아이템-잠재 요인 행렬(Q)****로 분해합니다.

$$R \approx P \times Q^T$$

- **R** : 원본 평점 행렬 (사용자 M $\times$ 아이템 N)
- **P** : 사용자-잠재 요인 행렬 ($M \times K$) $\rightarrow$ 사용자의 취향 벡터
- **Q** : 아이템-잠재 요인 행렬 ($N \times K$) $\rightarrow$ 아이템의 특성 벡터
- **K** : 잠재 요인의 개수 (예: 장르, 분위기 등)

3. 잠재 요인의 이해 (예시: 영화)

잠재 요인은 수학적으로 추출되지만, 개념적으로는 **장르 선호도**로 이해할 수 있습니다.

- **사용자 요인 (\$p_u\$):** "이 사용자는 액션을 0.9만큼 좋아하고, 로맨스를 0.1만큼 좋아한다."
- **아이템 요인 (\$q_i\$):** "이 영화는 액션 요소가 0.8이고, 로맨스 요소가 0.2인 영화다."
- **결과:** 두 값을 곱하면 해당 사용자가 이 영화에 줄 **예측 점수**가 나옵니다.

4. 구체적인 방식: 확률적 경사 하강법 (SGD)

실제 평점이 있는 데이터만 사용해 오차를 최소화하는 방향으로 행렬을 업데이트합니다.

① 예측 평점 계산

사용자 \$u\$가 아이템 \$i\$에 줄 예측 평점(\$\hat{r}_{u,i}\$)은 두 벡터의 내적으로 구합니다.

$$\hat{r}_{u,i} = p_u \cdot q_i^T$$

② 비용 함수 (Cost Function)

예측값과 실제값의 차이(오차)를 최소화하되, 모델이 과하게 복잡해지는 것(과적합)을 막기 위해 L2 규제를 추가합니다.

$$L = \sum (r_{u,i} - \hat{r}_{u,i})^2 + \lambda (||p_u||^2 + ||q_i||^2)$$

③ 행렬 업데이트 규칙

오차(\$e_{u,i} = r_{u,i} - \hat{r}_{u,i}\$)를 계산한 후, 아래 수식을 통해 \$p_u\$와 \$q_i\$ 값을 조금씩 수정합니다.

- $p_u \leftarrow p_u + \eta (e_{u,i} \cdot q_i - \lambda \cdot p_u)$
- $q_i \leftarrow q_i + \eta (e_{u,i} \cdot p_u - \lambda \cdot q_i)$

| (\$\eta\$: 학습률, \$\lambda\$: 규제 계수)

5. 진행 과정 요약

1. **초기화:** \$P\$와 \$Q\$ 행렬을 임의의 작은 난수로 채웁니다.
2. **반복:**

- 현재의 \$P, Q\$를 곱해 예측 평점을 구합니다.
 - 실제 평점과의 오차를 계산합니다.
 - **SGD 업데이트 수식**을 적용해 \$P, Q\$의 값을 조금씩 변경합니다.
3. **완료:** 오차가 충분히 작아질 때까지 반복하면 비어 있던 평점 칸을 모두 채울 수 있는 최적의 \$P, Q\$ 행렬이 완성됩니다.
 4. **추천:** 아직 보지 않은 영화 중 예측 평점이 가장 높은 영화를 사용자에게 추천합니다.

surprise 패키지

1. 다양한 추천 알고리즘, 예를 들어 사용자 또는 아이템 기반 최근접 이웃 협업 필터링, SVD, SVD++, NMF 기반의 잠재 요인 협업 필터링을 쉽게 적용해 추천 시스템을 구축할 수 있습니다.
2. Surprise의 핵심 API는 사이킷런의 핵심 API와 유사한 API명으로 작성되었습니다. 예를 들어 `fit()`, `predict()` AP로 추천 데이터 학습과 예측, `train_test_split()`으로 추천 학습 데이터 세트와 예측 데이터 세트 분리, `cross_validate()`, `GridSearchCV` 클래스를 통해 추천 시스템을 위한 모델 선택, 평가, 하이퍼 파라미터 튜닝 등의 기능을 제공합니다.

Prediction 객체는 Surprise 패키지에서 제공하는 데이터 타입이며, 개별 사용자 아이디(uid), 영화{또는 아이템} 아이디(iid)와 실제 평점(r_ui) 정보에 기반해 Surprise의 추천 예측 평점(est) 데이터를 튜플 형태로 가지고 있습니다.

주요 모듈:

API 명	내용
<code>Dataset.load_builtin</code> (<code>name='ml-100k'</code>)	무비렌즈 아카이브 FTP 서버에서 무비렌즈 데이터를 내려받습니다. ml-100k, ml-1M를 내려받을 수 있습니다. 일단 내려받은 데이터는 <code>.surprise_data</code> 디렉터리 밑에 저장되고, 해당 디렉터리에 데이터가 있으면 FTP에서 내려받지 않고 해당 데이터를 이용합니다. 입력 파라미터인 <code>name</code> 으로 대상 데이터가 ml-100k인지 ml-1m인지를 입력합니다(<code>name='ml-100k'</code>). 디폴트는 ml-100k입니다.

API 명	내용
<code>Dataset.load_from_file</code> (file_path, reader)	OS 파일에서 데이터를 로딩할 때 사용합니다. 콤마, 탭 등으로 칼럼이 분리된 포맷의 OS 파일에서 데이터를 로딩합니다. 입력 파라미터로 OS 파일명, Reader로 파일의 포맷을 지정합니다.
<code>Dataset.load_from_df</code> (df, reader)	판다스의 DataFrame에서 데이터를 로딩합니다. 파라미터로 DataFrame을 입력받으며 DataFrame 역시 반드시 3개의 칼럼 인 사용자 아이디, 아이템 아이디, 평점 순으로 칼럼 순서가 정해져 있어야 합니 다. 입력 파라미터로 DataFrame 객체, Reader로 파일의 포맷을 지정합니다.

- `linejormat (string)` : 칼럼을 순서대로 나열합니다. 입력된 문자열을 공백으로 분리해 칼럼으로 인식합니다.
- `sep (char)` : 칼럼을 분리하는 분리자이며, 디폴트는 V입니다. 판다스 DataFrame에서 입력받을 경우에는 기재할 필요가 없습니다.
- `rating_scale (tuple, optional)` : 평점 값의 최소 ~ 최대 평점을 설정합니다. 디폴트는 (1, 5)이지만 ratings.csv 파일의 경우는 최소 평점이 0.5, 최대 평점이 5이므로 (0.5, 5)로 설정했습니다.

1. 잠재 요인 협업 필터링 (행렬 분해 기반)

가장 대중적이고 성능이 우수한 알고리즘들입니다.

- **SVD (Singular Value Decomposition)**: 행렬 분해를 통한 가장 대표적인 잠재 요인 협업 필터링 알고리즘입니다²²²². 사용자 편향(User Bias)과 아이템 편향(Item Bias)을 반영하며, 과적합을 방지하기 위한 L2 규제를 적용한 비용 함수를 사용합니다³.
- **SVD++**: 기존 SVD 알고리즘에 사용자의 **암묵적 선호도(Implicit Feedback)**까지 고려하여 성능을 개선한 모델입니다⁴⁴⁴. RMSE 성능이 가장 우수하지만, 계산 시간이 매우 오래 걸린다는 단점이 있습니다⁵.
- **NMF (Non-negative Matrix Factorization)**: 행렬 분해 시 모든 원소 값을 양수로 제한하는 알고리즘으로, 잠재 요인 기반의 추천을 수행합니다⁶⁶⁶.

2. 최근접 이웃 협업 필터링 (KNN 기반)

데이터 간의 유사도를 측정하여 추천하는 방식입니다.

- **KNNBasic**: 가장 기본적인 최근접 이웃 협업 필터링 알고리즘입니다⁷⁷.
- **KNNWithMeans**: 사용자의 평균 평점을 고려한 KNN 알고리즘입니다. (텍스트 내 알고리즘 유형 표 참고)

- **KNNBaseline**: 최근접 이웃 방식에 **베이스라인 평점(Baseline Rating)** 개념을 결합한 모델입니다8. KNN 모델 중에서는 가장 성능 평가 수치가 좋습니다9.

3. 베이스라인 및 기타 알고리즘

- **BaselineOnly**: 전체 평균, 사용자 편향, 아이템 편향만을 고려하여 평점을 예측하는 기본적인 베이스라인 알고리즘입니다10101010.
- **Slope One**: 단순하면서도 효율적인 평점 예측 알고리즘입니다11.
- **Co-Clustering**: 사용자나 아이템을 그룹화(Clustering)하여 그 결과를 바탕으로 협업 필터링을 수행합니다12.

[참고] 주요 모델의 성능 및 특징 비교 13

알고리즘 유형	정확도(RMSE)	특징
SVD++	가장 우수	정확도가 가장 높으나 학습 시간이 매우 김 (약 9분 소요)
SVD	우수함	정확도와 속도(약 11초)의 균형이 좋아 가장 널리 쓰임
k-NN Baseline	우수함	KNN 기반 모델 중 가장 성능이 좋음
BaselineOnly	보통	매우 빠름(약 1초), 기본 편향성만 파악할 때 유용

베이스라인 평점

한 개인의 성향을 반영해 아이템 평가에 편향성(bias) 요소를 반영하여 평점을 부과하는 것을 베이스라인 평점 (Baseline Rating) 이라고 함.

전체 평균 평점 + 사용자 편향 점수 + 아이템 편향 점수 공식으로 계산

전체 평균 평점 = 모든 사용자의 아이템에 대한 평점을 평균한 값

사용자 편향 점수=사용자별 아이템 평점 평균 값 - 전체 평균 평점

아이템 편향 점수=아이템별 평점 평균 값 - 전체 평균 평점

정리

1. 추천 시스템의 가치와 중요성

- **비즈니스 영향력**: 온라인 스토어 등에서 뛰어난 추천 시스템은 직접적인 매출 향상으로 이어집니다.

- **기업의 노력:** 예측 성능을 높이기 위해 정교한 알고리즘 개발과 데이터 수집에 막대한 투자가 이루어지고 있습니다.

2. 콘텐츠 기반 필터링 (Content-based Filtering)

- **원리:** 아이템(영화, 상품 등) 자체의 속성을 분석하여 사용자가 과거에 좋아했던 아이템과 유사한 콘텐츠를 가진 다른 아이템을 추천합니다.
- **특징:**
 - 영화의 경우 장르, 감독, 배우, 키워드 등의 요소를 활용합니다.
 - 이 요소들을 **피처 벡터화**한 후 유사도가 높은 아이템을 찾아냅니다.

3. 협업 필터링 (Collaborative Filtering)

사용자-아이템 평점 행렬에 기반하며, 크게 두 가지 방식으로 나뉩니다.

① 최근접 이웃(Nearest Neighbor) 방식

- **사용자 기반:** 유사한 성향을 가진 다른 사용자가 좋아하는 아이템을 추천합니다.
- **아이템 기반 (권장):** 특정 아이템을 좋아한 사용자들이 공통적으로 높게 평가한 다른 아이템을 추천합니다. 실무에서 더 자주 사용됩니다.
- **방법:** 사용자 평점 데이터를 벡터화하여 **코사인 유사도**를 측정하고 Top-N 아이템을 추출합니다.

② 잠재 요인(Latent Factor) 방식

- **원리:** 사용자-아이템 평점 행렬 속에 숨겨진 '잠재적 특성(요인)'을 추출하여, 사용자가 아직 평가하지 않은 아이템의 점수를 예측합니다.
- **핵심 기술 (행렬 분해):** 고차원의 행렬을 저차원의 '사용자-잠재요인' 행렬과 '아이템-잠재요인' 행렬로 분해하는 **행렬 분해(Matrix Factorization)** 기법을 사용합니다.
- **최적화:** 주로 **경사 하강법(Gradient Descent)**을 이용해 오차를 최소화하며 모델을 구현합니다.

4. 파이썬 추천 시스템 패키지: Surprise

- **특징:** 사이킷런(Scikit-learn)과 유사한 API 구조를 가지고 있어 사용이 매우 편리합니다.
- **장점:** 복잡한 구현 로직을 간소화하여 파이썬 환경에서 빠르게 추천 시스템을 구축할 수 있게 도와줍니다.